



幂法

董波
数学科学学院
大连理工大学





幂法、反幂法作用

求方阵的全部特征值

求特征多项式的方法 计算量大

实际应用中仅需矩阵的**极端特征值**

模最大特征值

幂法


模最小特征值

反幂法


应用：Pagerank



$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \quad \lambda=1 \quad x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$



$$\begin{pmatrix} 0 & 1 & 0 \\ 1/2 & 0 & 1 \\ 1/2 & 0 & 0 \end{pmatrix} \quad \lambda=1 \quad x = \begin{pmatrix} 2 \\ 2 \\ 1 \end{pmatrix}$$



$$\begin{pmatrix} 0 & 1/2 & 0 & 1/3 \\ 1/3 & 0 & 1 & 1/3 \\ 1/3 & 0 & 0 & 1/3 \\ 1/3 & 1/2 & 0 & 0 \end{pmatrix} \quad \lambda=1 \quad x = \begin{pmatrix} 3 \\ 4 \\ 2 \\ 3 \end{pmatrix}$$

最大特征值1对应的特征向量反映重要性

幂法

假定 n 阶方阵 A 可对角化，其特征值和对应的特征向量分别为

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n| \quad x_1 \quad x_2 \quad \dots \quad x_n$$

对任一 n 维向量 v ，均可表示为 $v = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$ 。故

$$Av = A(\alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n) = \alpha_1 \lambda_1 x_1 + \alpha_2 \lambda_2 x_2 + \dots + \alpha_n \lambda_n x_n$$

从而

$$A^k v = \alpha_1 \lambda_1^k x_1 + \alpha_2 \lambda_2^k x_2 + \dots + \alpha_n \lambda_n^k x_n = \lambda_1^k \left(\alpha_1 x_1 + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k x_2 + \dots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k x_n \right)$$

有

$$\frac{A^k v}{\lambda_1^k} \rightarrow \alpha_1 x_1 \quad \frac{A^k v}{A^{k-1} v} \rightarrow \lambda_1$$

收敛速度取决于比值 λ_2/λ_1 的大小

幂法流程

幂法的本质是 $v_k = A^k v_0$

算法流程:

任取一个非零初始向量 $v_0 \in R^n$

$$v_1 = Av_0$$

$$v_2 = A^2 v_0 = Av_1$$

$$v_{k+1} = A^{k+1} v_0 = Av_k$$

存在问题:

$\alpha_1 = 0$ 将会怎样?

重新选择初始向量

迭代向量的各个不等于零的分量将随 $k \rightarrow \infty$ 而趋于无穷

规范化迭代向量



幂法

假定 n 阶方阵 A 具有 n 个线性无关的特征向量

$$x_1 \quad x_2 \quad \dots \quad x_n$$

且对应的特征值满足

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$$

则对任一 n 维非零向量 v_0 ，经使用迭代过程

$$v_k = A^k v_0$$

计算可得

$$v_k = \alpha_1 \lambda_1^k x_1, \quad \alpha_1 \neq 0 \quad \frac{v_k}{v_{k-1}} = \lambda_1$$

幂法改进

任取初始向量: $v_0 \neq 0$

迭代

$$v_1 = Av_0,$$

$$v_2 = Au_1 = \frac{A^2 v_0}{\max(Av_0)},$$

\vdots

$$v_k = Au_{k-1} = \frac{A^k v_0}{\max(A^{k-1} v_0)},$$

\vdots

规范化

$$u_1 = \frac{v_1}{\max(v_1)} = \frac{Av_0}{\max(Av_0)}$$

$$u_2 = \frac{v_2}{\max(v_2)} = \frac{A^2 v_0}{\max(A^2 v_0)}$$

\vdots

$$u_k = \frac{v_k}{\max(v_k)} = \frac{A^k v_0}{\max(A^k v_0)}$$

\vdots

则有迭代向量序列 $\{v_k\}$ 及规范化向量序列 $\{u_k\}$ 。

收敛性分析

$$u_k = \frac{v_k}{\max(v_k)} = \frac{\lambda_1^k \left(\alpha_1 x_1 + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k x_2 + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k x_n \right)}{\max \left(\lambda_1^k \left(\alpha_1 x_1 + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k x_2 + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k x_n \right) \right)} \rightarrow \frac{x_1}{\max(x_1)}$$

$$v_k = \frac{A^k v_0}{\max(A^{k-1} v_0)} = \frac{\lambda_1^k \left(\alpha_1 x_1 + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k x_2 + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^k x_n \right)}{\max \left(\lambda_1^{k-1} \left(\alpha_1 x_1 + \alpha_2 \left(\frac{\lambda_2}{\lambda_1} \right)^{k-1} x_2 + \cdots + \alpha_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k-1} x_n \right) \right)}$$

于是, $\mu_k = \max(v_k) \rightarrow \lambda_1$



复杂情形

- 重特征值 $\lambda_1 = \lambda_2 = \cdots = \lambda_r$
 - $\lambda_1 = \lambda_2 = \cdots = \lambda_r = -\lambda_{r+1} = \cdots = -\lambda_{r+s}$
 - $\lambda_1 = \lambda_2 = \cdots = \lambda_r = \bar{\lambda}_{r+1} = \cdots = \bar{\lambda}_{r+s}$
-

反幂法

作用：反幂法用来计算矩阵 A 按模最小的特征值及对应的特征向量

1. 假设实矩阵 A 具有 n 个线性无关的特征向量 x_1, x_2, \dots, x_n
2. 相应的特征值满足 $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_{n-1}| > |\lambda_n| > 0$

反幂法：对于 A^{-1} 应用幂法：对于给的初始向量 v_0

$$\begin{cases} u_k = A^{-1}v_{k-1} \\ v_k = u_k / \max(u_k) \end{cases} \xrightarrow{\text{避免求逆}} \begin{cases} Au_k = v_{k-1} \\ v_k = u_k / \max(u_k) \end{cases} \xrightarrow{A=LU} \begin{cases} Lw_k = v_{k-1} \\ Uu_k = w_k \\ v_k = u_k / \max(u_k) \end{cases}$$

带原点平移的反幂法：对 $(A - pI)^{-1}$ 用幂法

$$\begin{cases} u_k = (A - pI)^{-1}v_{k-1} \\ v_k = u_k / \max(u_k) \end{cases} \xrightarrow{\text{避免求逆}} \begin{cases} (A - pI)u_k = v_{k-1} \\ v_k = u_k / \max(u_k) \end{cases} \xrightarrow{A-pI=LU} \begin{cases} Lw_k = v_{k-1} \\ Uu_k = w_k \\ v_k = u_k / \max(u_k) \end{cases}$$